

Laporan Praktikum Minggu Ke-5 Kontrol Cerdas

Minggu ke-5

Nama : Syahda Nur Wijaya

NIM : 224308071

Kelas : TKA 7C

Akun Github (Tautan): <https://github.com/syahdanurwijaya>

1. Judul Percobaan

Deep Reinforcement Learning untuk Kontrol Kompleks

2. Tujuan Percobaan

Tujuan dari percobaan ini, sebagai berikut:

- a. Memahami konsep Deep Reinforcement Learning (DRL) dalam kontrol sistem kompleks.
- b. Mengimplementasikan Deep Q-Network (DQN) untuk kontrol otomatis.
- c. Menganalisis performa DRL dibandingkan dengan metode kontrol konvensional.

3. Landasan Teori

Deep Reinforcement Learning (DRL) merupakan pengembangan dari Reinforcement Learning (RL) yang mengintegrasikan penggunaan Neural Network untuk mengatasi permasalahan pada ruang state yang kompleks dan bersifat kontinyu. Metode DRL menggantikan representasi Q-Value yang bersifat tabel (Q-Table) pada RL klasik dengan Neural Network, sehingga mampu menangani skala masalah yang lebih besar dan state yang lebih kompleks secara efektif.

DQN adalah algoritma DRL yang paling umum digunakan untuk kontrol adaptif. DQN menggantikan tabel Q-value dengan Neural Network yang

memprediksi nilai Q untuk setiap aksi pada state yang diberikan. Arsitektur DQN terdiri dari beberapa lapisan Neural Network yang menerima input berupa state lingkungan (sensor, kondisi sistem, dll), dan menghasilkan output berupa nilai Q untuk setiap aksi yang mungkin diambil. Proses pelatihan DQN menggunakan fungsi loss berupa Mean Squared Error antara prediksi dan target Q-Value, serta memanfaatkan replay memory untuk menyimpan pengalaman agar pelatihan menjadi lebih stabil (Ridho Amanda Putra, 2024).

Aplikasi DRL dalam sistem kendali meliputi: kontrol kendaraan otonom dalam navigasi yang kompleks, robot industri yang mampu menyesuaikan strategi berdasarkan lingkungan yang dinamis, serta optimasi sistem tenaga listrik untuk efisiensi energi. Implementasi DRL khususnya DQN dapat dilakukan dengan framework TensorFlow dan OpenAI Gym, menggunakan teknik seperti experience replay untuk stabilisasi pelatihan dan epsilon-greedy strategy guna menyeimbangkan eksplorasi dan eksploitasi dalam pengambilan keputusan.

4. Diskusi

a. Apa kelebihan dan kelemahan DQN dibandingkan metode Q-Learning klasik?

Kelebihan DQN:

- Menggunakan jaringan saraf dalam (Deep Neural Network) untuk mengaproksimasi Q-value, sehingga dapat menangani ruang state yang sangat besar dan kontinu, berbeda dengan Q-Learning yang memakai Q-table terbatas untuk state diskrit kecil.
- Memiliki kemampuan generalisasi yang lebih baik, memungkinkan model untuk memahami pola dan menerapkan pengetahuan ke state-state baru.
- Stabilitas pembelajaran ditingkatkan dengan teknik Experience Replay dan Target Network yang mengurangi korelasi data dan osilasi parameter.

Kelemahan DQN:

- Memerlukan lebih banyak sumber daya komputasi dan waktu pelatihan dibanding Q-Learning sederhana.
 - Lebih kompleks dalam implementasi dan tuning hyperparameter.
 - Kadang sulit konvergen pada lingkungan yang sangat dinamis atau dengan noise tinggi.
- b. Bagaimana cara mengadaptasi DQN untuk kontrol sistem dinamis seperti drone atau robot industri?
- Gunakan sensor real-time (gambar kamera, lidar, IMU) dan proses data menggunakan CNN atau RNN agar state bisa mewakili kondisi lingkungan dan sistem secara utuh.
 - Modifikasi DQN dengan metode seperti DDPG (Deep Deterministic Policy Gradient) atau menggunakan teknik discretization jika aksi bersifat kontinu.
 - Rancang fungsi reward yang mengarahkan sistem ke tujuan kontrol (misal stabilitas posisi, efisiensi energi).
 - Terapkan experience replay untuk menghindari korelasi antar data, dan target network untuk mengurangi fluktuasi dalam pembelajaran.
 - Latih model di simulasi yang realistis untuk menekan risiko kegagalan sebelum deploy ke sistem nyata, dan gunakan transfer learning untuk adaptasi cepat.
 - Integrasikan DQN dengan kontrol klasik (PID, MPC) untuk lapisan kontrol yang lebih stabil dan responsif.

5. Assignment


Pada praktikum ini menggunakan algoritma MediaPipe yang mampu mendeteksi hingga 21 titik kunci (landmarks) pada setiap tangan, sehingga dapat menghasilkan informasi detail tentang posisi dan pose tiap jari dan telapak tangan yang terdeteksi. Dengan bantuan OpenCV, hasil deteksi divisualisasikan secara langsung pada layar berupa bounding box berwarna hijau yang mengelilingi area tangan serta label “Left Hand” dan “Right Hand”




untuk membedakan tangan kiri dan kanan berdasarkan hasil klasifikasi MediaPipe.

Dengan menggunakan kotak pembatas berlabel keyakinan dan penanda individual untuk masing-masing tangan, sistem ini tidak hanya dapat digunakan untuk pengenalan gestur, tetapi juga untuk aplikasi yang membutuhkan interaksi simultan antara banyak pengguna. Sistem ini juga memperhitungkan perubahan kondisi lingkungan, seperti perubahan postur dan orientasi tangan, sehingga sangat fleksibel untuk digunakan dalam berbagai skenario, seperti pengenalan gestur untuk presentasi, aplikasi interaktif, dan bahkan kontrol visual robot. Secara keseluruhan, deteksi dan visualisasi tangan dalam praktikum ini telah memperlihatkan kapabilitas tinggi dari MediaPipe dan OpenCV dalam machine vision, terutama dalam aspek kecepatan respon dan akurasi deteksi multi-tangan secara real-time, yang dapat diadaptasi lebih lanjut untuk berbagai aplikasi kecerdasan buatan dan interaksi manusia-komputer di masa depan.

6. Data dan Output Hasil Pengamatan

Pada praktikum ini di dapatkan hasil pengujian untuk mendeteksi dan melacak posisi tubuh serta tangan manusia secara real-time melalui kamera web sebagai berikut:

No	Variable	Hasil Pengamatan	Keterangan
1.	Deteksi 2 Tangan		sistem komputer yang mendeteksi tangan kiri dan kanan menggunakan OpenCV dan MediaPipe, lalu memberikan kotak hijau serta label “Left Hand” dan “Right Hand” pada masing-masing tangan.

			
2.	Deteksi Multi Tangan		Jumlah tangan yang dapat terdeteksi melebihi 2 tangan. Setiap sendi dapat terdeteksi dan jumlah sendi terdeteksi ada 20.
3.	Deteksi Badan		Program dapat mendeteksi tubuh manusia secara baik dan mendeteksi setiap sendinya.

7. Kesimpulan

Berdasarkan praktikum, analisis, dan hasil yang telah dilakukan, dapat disimpulkan bahwa:

- Sistem mampu berjalan dengan baik seperti halnya mendeteksi bagian tubuh manusia saja tanpa adanya noise yang terdeteksi, sehingga dapat menghasilkan deteksi secara real-time.
- Program mampu mengidentifikasi titik-titik kunci pada tangan dan seluruh tubuh, menggambar skeleton dan bounding box yang informatif, serta menampilkan label lengkap dengan confidence score.
- Tingkat akurasi model sangat bergantung pada dataset yang ada.

8. Saran

1. Sebaiknya pengembangan dan peningkatan praktikum ini antara lain adalah memperhatikan pencahayaan dan posisi kamera agar deteksi keypoints lebih akurat dan stabil, terutama saat menggerakkan tangan atau seluruh tubuh dengan cepat.
2. Disarankan untuk menambahkan fitur kalibrasi awal untuk meningkatkan akurasi deteksi pada variasi ukuran tubuh dan posisi jarak dengan kamera.

9. Daftar Pustaka

Ridho Amanda Putra. (2024). *ANALISIS DEEP Q-NETWORK (DQN) UNTUK SIMULASI LAMPU LALU LINTAS ADAPTIF BERDASARKAN WAKTU TUNGGU KENDARAAN.*